

**第 讯 大 数 据 技 术 系 列 沙 龙 第 9 期** 

### 云原生数据湖专场

协办方

Tencent **のpen** / 腾讯开源



直播支持

腾讯大讲堂

Z

G

D

### 腾讯云原生统一元数据的设计与构建

Z

Z

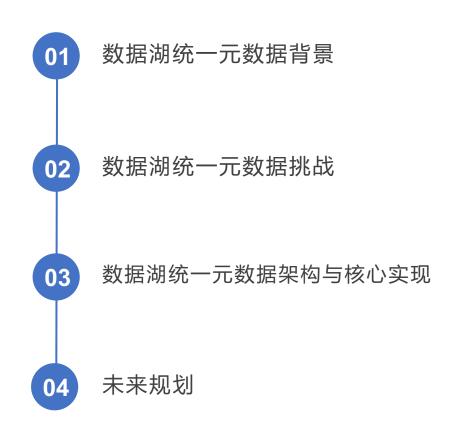
В

G

D

吴怡雯

### 目录/Contents



### 数据湖统一元数据背景

数据湖:集中式存储原始的、海量的、多来源、多类型的数据,支持数据的快速加工及计算 (包容性/快速落地)

统一元数据:数据湖实现基石,结构化数据管理,避免陷入数据沼泽



### 数据湖统一元数据现状

纵观整个元数据管理, 有不同的领域范畴和实践

#### 传统元数据管理

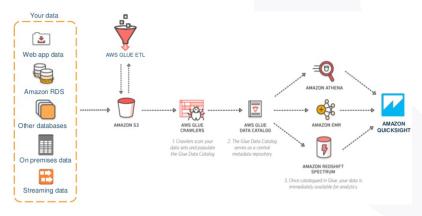
数据资产管理的核心职能领域之一 元模型定义、元数据采集/存储/应用 Apache Atlas、Linkedin DataHub、Netflix Metacat 无事务保证、无在线数据目录功能



#### Hive MetaStore管理

SQL on Hadoop的数据目录 单租户、分区管理瓶颈、治理能力较弱







### 云厂商实践:AWS GLUE

云上多租户/多类型/多存储兼容的元数据目录管理 元数据发现:文本推断、爬虫采集 无数据治理能力,可与外部数据治理组件结合

### 数据湖统一元数据挑战

目标:云上多租户的元数据统一管理

➤ 多业务统一: DLC、DLF、WeData

▶ 多引擎统一:分析引擎、表格式、数据编排

▶ 在线离线统一:OLTP 目录管理、OLAP数据治理

### 异构数据源

多类型数据源/抽象元模型(通用/可继承) 避免新增数据源,导致改造成本线性增长

#### 元数据量级

元数据海量/数据量稀疏/租户设计



#### 场景多样性

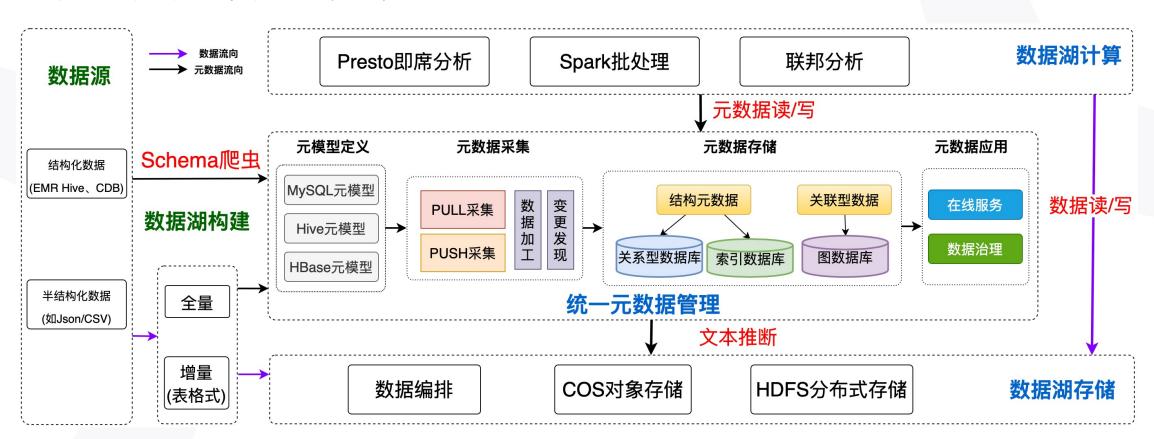
在线数据目录/数据湖治理 架构设计、底层存储选型

多引擎适配

通用性及低成本改造
Presto/Spark/Hive/Iceberg/Alluxio

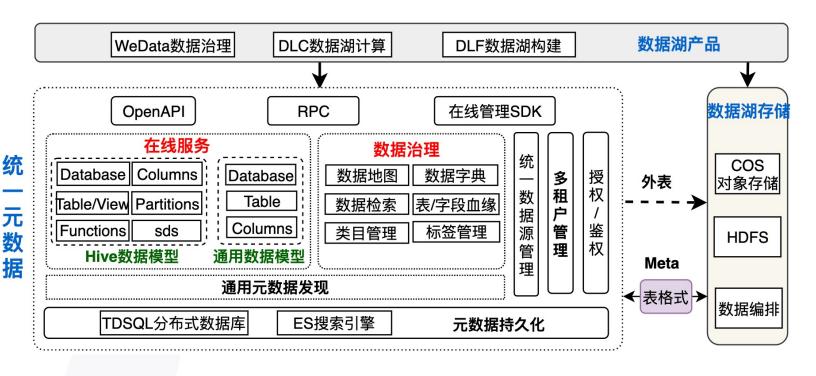
### 数据湖整体架构

三大支撑模块 + 两大核心组件 统一元数据是整个数据湖的总线



### 数据湖统一元数据架构

完全自研 统一元数据微服务基于云上Kubernetes编排部署



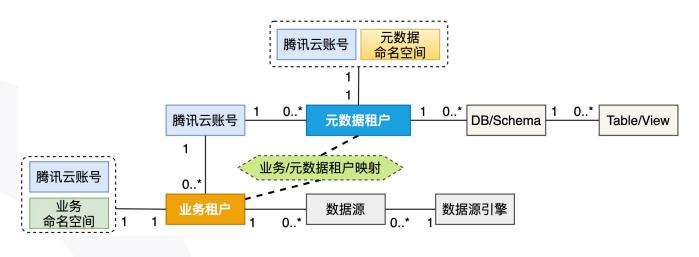
#### 核心技术

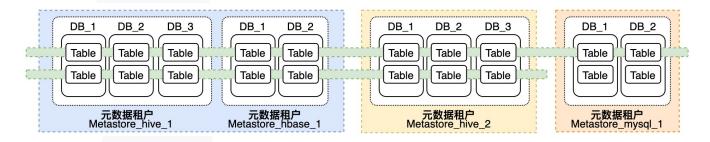
- ▶ 通用多租户管理
- ➤ 兼容HMS的在线数据目录
- ▶ 丰富的数据治理能力
- ▶ 轻量且通用的元数据发现

实现云上统一元数据的基本框架与根基

# 核心实现-租户设计

公有云SaaS服务设计前提:抽象租户模型







#### 元数据租户

- 一个元数据租户类比一个Hive MetaStore
- 腾讯云账号下支持多个元数据租户
- ▶ 腾讯云账号+元数据命名空间=元数据租户
- 元数据租户支持不同类型:Hive、MySQL等

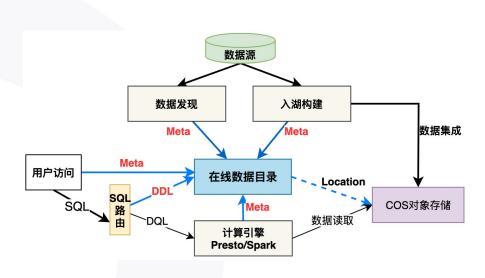


#### 业务租户

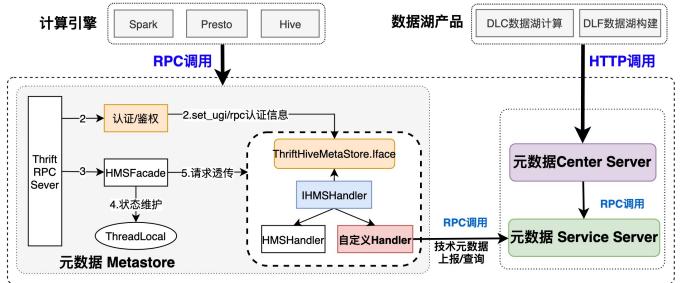
- 解耦通用的元数据与具体业务的强绑定关系
- ▶ 业务租户与具体业务的使用场景挂钩
- 🎐 业务租户与元数据租户无直接关系,通过灵活映射表维护
- 业务租户横向划分(私有化:部门/项目), 纵向划分(产品)

# 核心实现-在线目录

- ➤ Hive MetaStore是Hadoop生态圈中元数据目录管理的事实标准
- ➤ 友好且低成本多引擎对接,兼容实现Hive Metastore的原生RPC接口
- ➤ RPC调用接口认证/鉴权的安全增强
- ▶ 基于用户认证信息可自动识别元数据租户



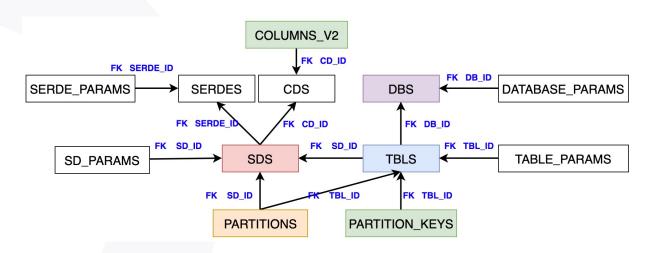
使用场景



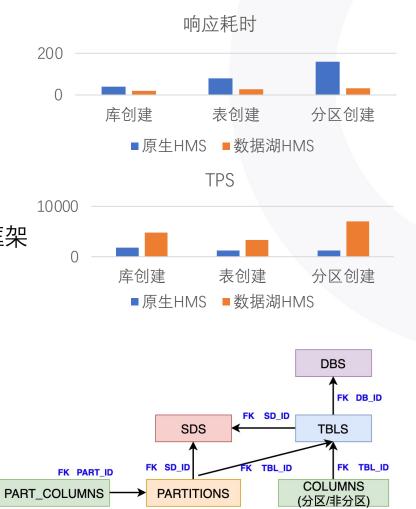
调用实现流程图

### 核心实现-在线目录

- ➤ 关注数据模型: DB/Table/Columns/Partitions
- ▶ 简化数据模型关系(12 -> 6), 并增加租户与业务元数据的维护
  - ► KV配置参数关联表以JSON字段存储
  - 字段元模型通用化:分区/非分区字段
  - ▶ 存储格式SDS简化
- ▶ 性能显著提升:数据模型简化、底层存储、减少锁、持久化框架



Hive MetaStore数据模型



统一元数据数据模型

# 核心实现-数据治理

### 提供丰富完善的数据治理能力













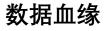






#### 数据地图

全局数据检索 数据大盘/总览 数据字典 数据资产盘点



多方言SQL血缘解析 表级/字段级血缘 **链路分析** 

### 数据规范

业务自定义类目 数仓建模 数据主题 高效共享

### 数据质量

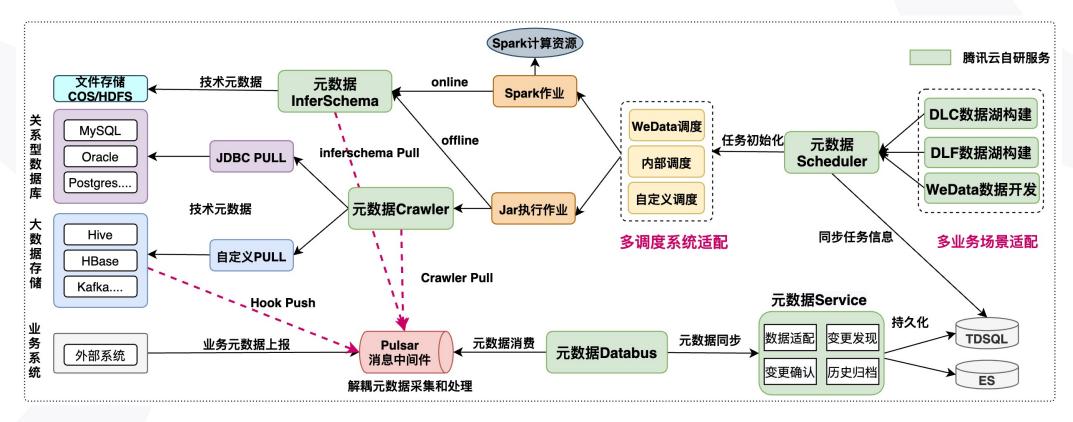
质量模型 规则引擎/标准校验 **优质数据资产** 

### 数据安全

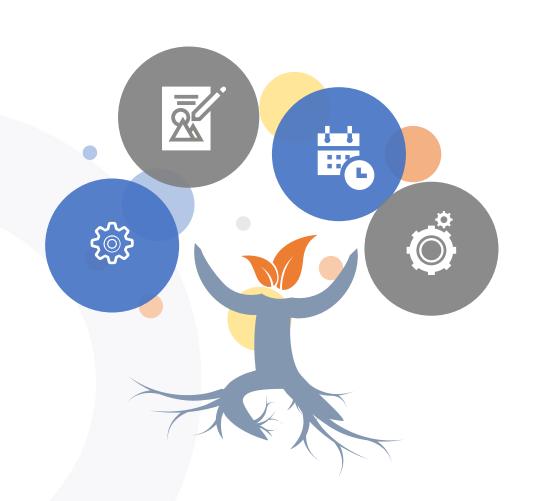
鉴权/授权 数据脱敏 数据分级 **合法合规** 

### 核心实现-元数据发现

- > 实现通用的轻量级元数据发现
- ▶ 支持:文本推断、数据引擎爬虫
- ▶ 优化:透明化上层业务与底层调度、采集逻辑抽象、消息解耦



获取元数据的重要途径



- ✓ 生命周期管理、元数据统计(CBO优化)
- 数据湖元数据与EMR Hive对接
- 元数据在线能力丰富
- 对外开放数据治理能力

# Q & A



"腾讯大数据"微信公众号



扫描二维码查看详细招聘信息



添加活动助手,加入 技术交流群