

## 实时湖仓功能架构设计与落地实战

主讲人: 灵江

# Part 1 功能架构介绍

## 实时湖仓功能架构



实时湖仓并不是一个独立的产品模块,它的完整实践是基于实时开发平台去落地的。

单独拆出架构图,是为了更直观地介绍我们建设实时湖仓的完整思路。



## 实时湖仓功能架构-湖仓管理



湖仓管理是建设实时湖仓的基础,通过这一层的建设,你可以:

- ·借助 Flink Catalog 管理,构建一套虚拟湖仓分层架构,类似传统离线数仓中的主题域、DW 分层设计
- 可视化创建湖表,平台支持 Paimon、Hudi、Iceberg 三种湖表创建,并分别提供对应的 DDL DEMO
- 通过Flink表管理,持久化存储基于 RDB、Kafka 创建的 Flink 映射表,和湖表一起,为实时计算提供表管理能力
- 作为实时计算领域最常用的数据介质,平台同时也支持对 Kafka Topic 进行基础的增删改查、数据统计分析等功能

## 实时湖仓功能架构-湖仓开发



湖仓开发是建设实时湖仓的核心能力,按应用场景主要分为:

- •数据入湖:通过实时消费 Kafka,或者读取 RDB 的 CDC 数据,将业务数据实时打入数据湖,构建实时湖仓的 ODS 层,为后续的流/批读写提供统一的数据基础
- 湖仓加工:借助湖表格式的事务特性、快照特性等能力,通过 FlinkSQL 任务读写湖表,构建湖仓中间层
- •流批一体:在湖仓加工过程中,根据不同的业务场景,可以选择流读或批读,在流批一体的设计上,你可以选择先批读存量数据,无缝衔接流读增量数据,也可以选择流读增量数据,批读进行数据订正

## 实时湖仓功能架构-湖仓治理



在湖仓开发过程中,我们可以通过湖仓治理能力,不断优化完善实时湖仓:

- 湖表文件治理:在湖仓开发过程中,会产生大量小文件、过期快照、孤儿文件等数据,严重影响湖表的读写性能。通过文件治理功能,可以定期合并小文件、清理过期快照/孤儿文件,提高开发效率
- 元数据查询:在提供 Catalog/Database/Table 基础信息查询的同时,会对湖表的存储、行数、任务依赖等信息进行统计,方便全局判断湖表价值
- Hive 表转换:对于历史 Hive 表,平台支持在不影响历史数据的前提下,一键转换表类型

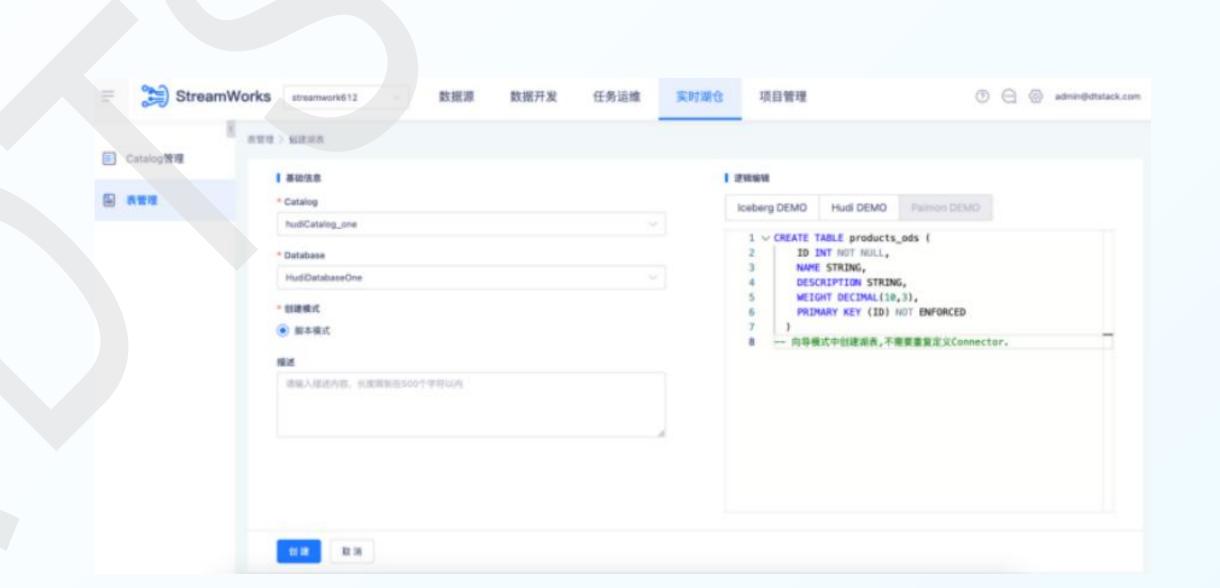
# Part 2 袋鼠云实操案例分享

## 第一步: 数据入湖(实时采集 DB2 数据,写入 PaimonA 湖表)



· 先创建 DB2-CDC 的 Flink 映射表和 Paimon 湖表

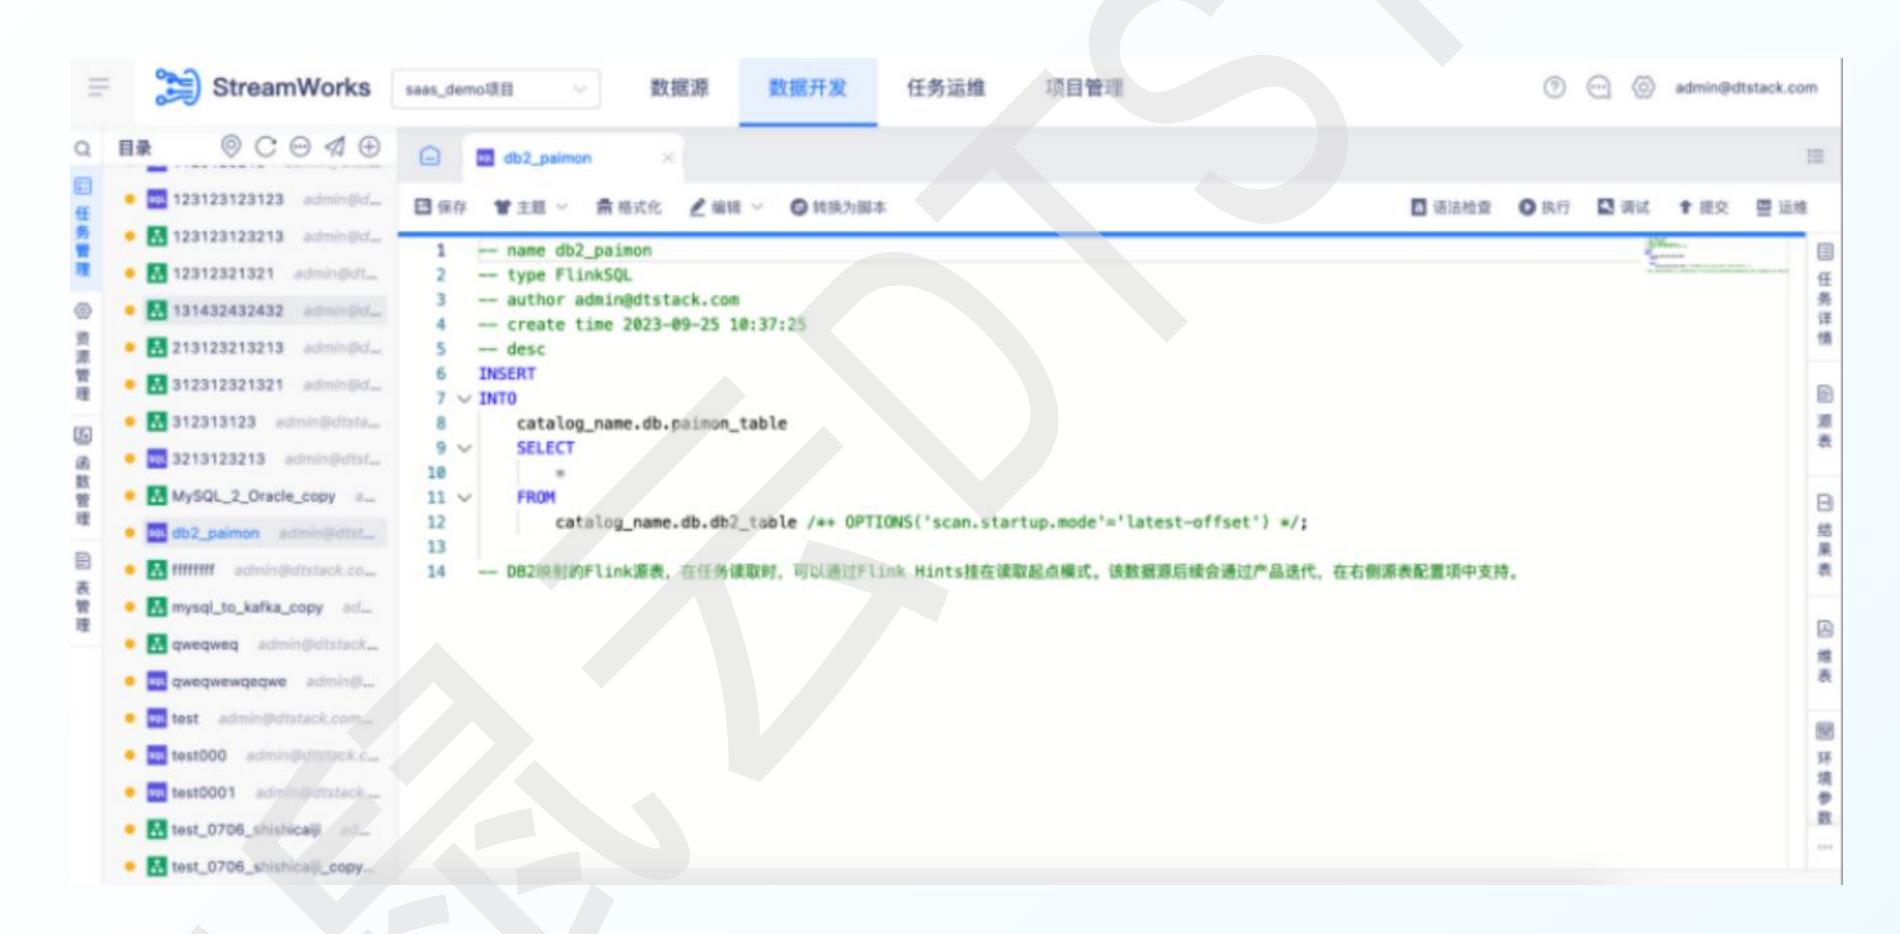




#### 数据入湖(实时采集 DB2 数据,写入 PaimonA 湖表)



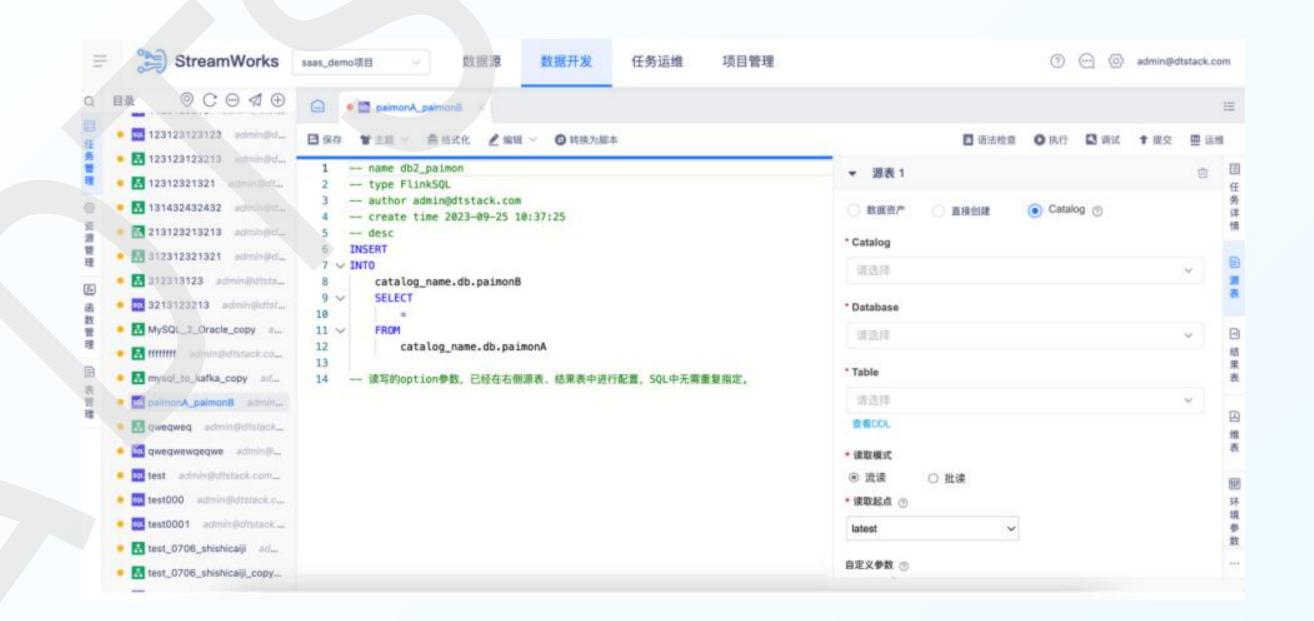
#### · 开发入湖任务



## 第二步: 湖仓开发(流式读取 PaimonA, 流式写入 PaimonB)



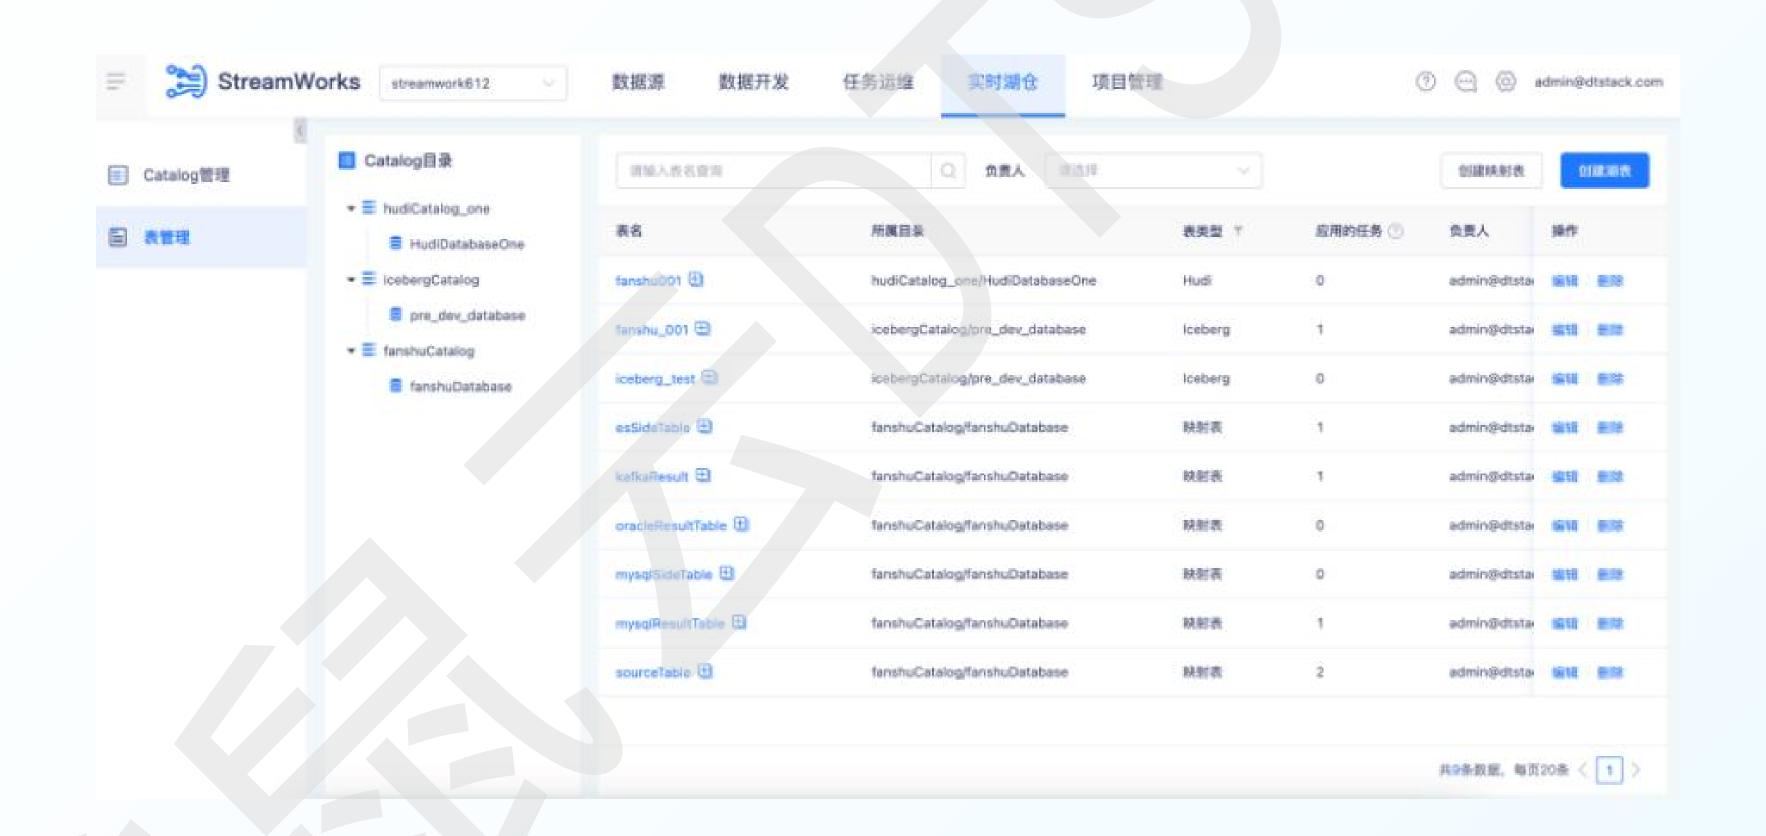
- 创建 PaimonB 的方式同上,此处不再重复演示
- 开发读写湖表任务。平台支持读写参数的配置化开发,无需在 SQL 代码中定义,极大的提高开发效率; (比如在湖表读取时选择时间戳,SQL开发时需要先在后台查询快照数据,并进行时间戳转换才能理解,配置化方式则可以直接选择/输入日期时间,在提交任务时自动转换时间戳)



### 第三步: 湖仓治理



·元数据查询:提供 Catalog、Database、湖表(Paimon/Hudi/Iceberg)、Flink 映射表的元数据查询。



## 第三步: 湖仓治理



·数据文件治理: 湖表的读写, 特别是实时场景下的读写, 会产生大量的小文件。小文件过多又会影响读取性能。因此对于湖表文件的治理功能, 是建设实时湖仓必不可缺的一部分。

₹ 数据入湖	任务模拟 > 新建模板				63
日 数据文件治理 ^	* Database	争数	<b>伊敦俊</b> 旧天政府	操作	扩展 數 數
任务模板	→ 全量数据库 ①				
任务实例记录	* Table	<b>主源加扩展参数</b>	(三) 超加多級		
	* 任务类型				环境参数
	N文件自并 Q				
	小文件合并				
	过期快航清理				
	孤儿文件清理				
	治理方式				
	<ul><li>立即治理</li><li>原約治理</li><li>原額治理</li></ul>				
	9.49 DOM				

## 总结



实时湖仓是「实时计算」和「数据湖」的一种结合应用场景,并不是具体指一个产品模块。平台通过相关功能的设计,让数据开发可以更简单更直观地了解 Flink Catalog、数据湖、流批一体等概念,并在实际业务场景中更方便地去落地实践。

#### 实时湖仓系列直播第一期视频:

https://www.bilibili.com/video/BV1Eu4y1Q7YQ/?spm\_id\_from=333.999.0.0

#### 第一期课件下载:

https://www.dtstack.com/resources/1050



## 让数据产生价值



袋鼠云服务号



行业交流群



资料获取

