

指标中台核心技术-开放 分析语言OAX设计

陈长林 快手大数据平台技术专家



关于我



陈长林, 快手大数据平台技术专家

2021年加入快手,曾在美团、阿里从事大数据领域和电商业务后端领域的研发工作。当前主要从事大数据领域BI数据产品、数据建模、分析语言等相关工作,在大数据数据分析领域建设有丰富实践经验。



目录 CONTENT

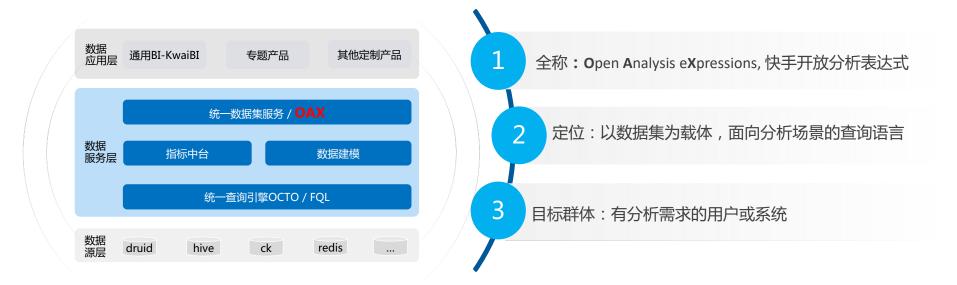
02 OAX语法设计 **04** 总结



01 OAX整体介绍



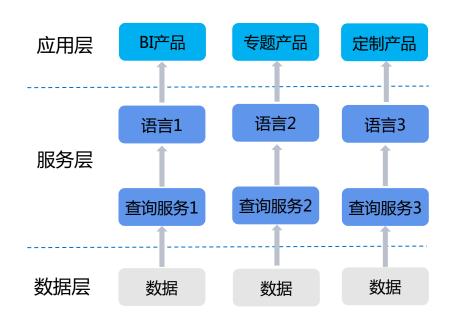
什么是OAX





OAX设计背景

烟囱式建设



面临的问题:

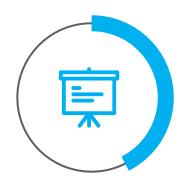
- 烟囱系统
- 规范缺乏
- 接入效率低

问题的解决:

- 统一,开放
- 建立统一规范



OAX设计指导原则



规范

- 分析模型
- 分析语法
- 访问协议



统一



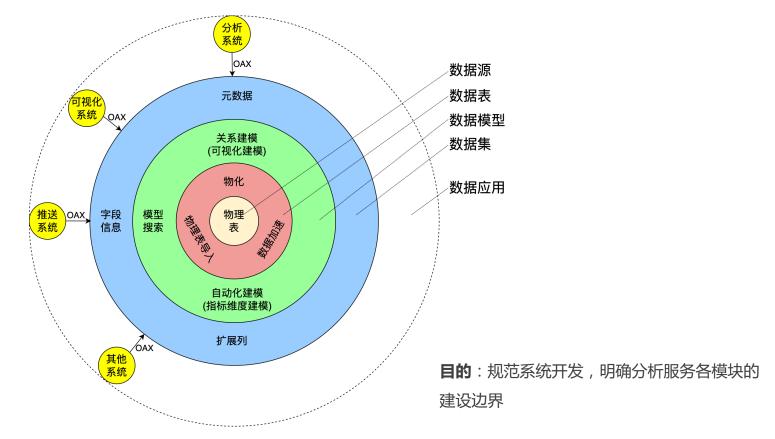


开放

- 功能扩展
- 外部使用

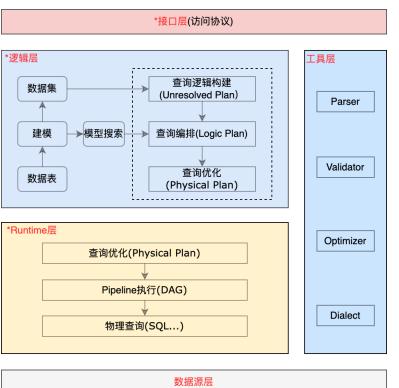


分析模型





OAX语言架构



接口层

用户访问分析服务入口,OAX提供了规范的访问协议

逻辑层 分析查询逻辑的构建,以执行计划树表示

Runtime层 查询逻辑的执行,执行计划的调度和执行,包含本地计算和分布式计算

工具层

提供对OAX语言的处理工具,包含对OAX的解析、验证、优化、方言处理,基于Apache Calcite扩展

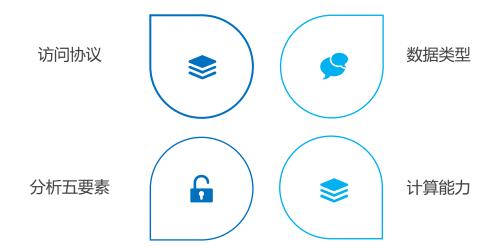




02 OAX语法设计



OAX表达分析需求





四种数据类型

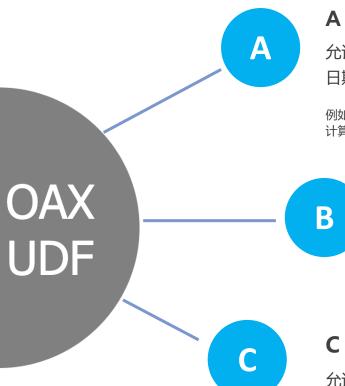


数据类型

- 文本 (String)
 - > 表达文本内容的数据类型
- 数值 (Numeric)
 - ▶ 表达整数、浮点数的数据类型。
- 日期 (DateTime)
 - ▶ 精确到毫秒的13位时间戳、表达时间语义的数据 类型。
- 布尔 (Boolean)
 - ▶ "真"(1)或"假"(0)中的一个。



三类计算能力



A 基本计算

允许用户在原始值或计算结果值粒度进行计算,分为:数字函数、字符串函数、 日期函数、类型转换、逻辑函数、聚合函数、指标函数、高级计算

例如: SUM([消耗]), CONCAT([姓], [名]), DATE_ADD('day', NOW(), 1),

计算周同比: YOY(SUM([消耗]), 1, 'week', 'value')

B 动态粒度计算

允许计算过程中改变数据计算粒度,可以在较高粒度(EXCLUDE)、较低粒度(INCLUDE)、独立粒度(FIXED)进行计算

例如计算各省的消耗占比: SUM([消耗]) / {EXCLUDE [省份]: SUM([消耗])}

C 表计算

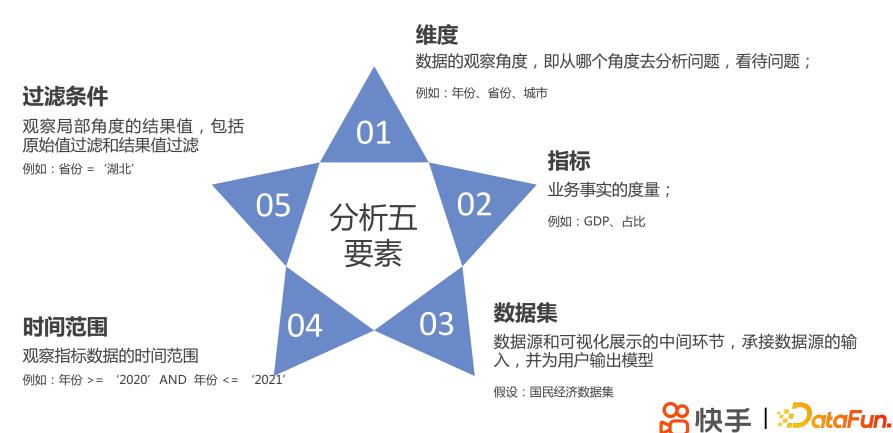
允许用户对结果值再进行计算,例如:滚动类函数、窗口类函数、偏移类函数等

例如要计算MTD消耗(本月1号至本月当前日期的消耗累计): RUNNING_SUM(SUM([消耗])) ALONG([日])



五个分析要素

分析需求:2020~2021年湖北省各市的GDP及占比



五要素的两种形式

PB形式

```
message OaxQuery {
repeated Select select = 1; //指标、维度
From from = 2; //数据集
Filter where = 3; //纬度值过滤
Filter context_where = 4; //上下文过滤器
Filter having = 5; //结果值过滤
repeated string group_by = 6;
repeated OrderBy order_by = 7;
LimitSpec limit = 8;
```

分析需求: 2020~2021年湖北省各市的GDP及占比

类SQL形式

```
1 SELECT select_expr [, ...] --指标、维度
2 FROM [ dataset_urn | sub_query ] --数据集
3 [ WHERE where_condition ] --纬度值过滤
4 [ CONTEXT_WHERE context_where_condition ] --上下文过滤
5 [ HAVING having_condition ] --结果值过滤
6 [ GROUP BY grouping_element [, ...] ]
7 [ ORDER BY expression [ ASC | DESC ][, ...] ]
8 [ LIMIT offset,size ]
```

```
SELECT 「年份」,
                                                           --维度
          [省份],
                                                           --维度
          「城市」,
                                                           --维度
         SUM([GDP]) AS gdp,
                                                           --指标
         SUM(「GDP]) / {EXCLUDE 「城市]: SUM(「GDP])} AS gdp_rate
                                                          --指标
   FROM 「国民经济数据集]
                                                           --数据集
   WHERE [年份] >= '2020' and [年份] <= '2021'
                                                           --时间范围
         AND [省份] IN ('湖北')
                                                           --过滤条件
   GROUP BY [年份], [省份], [城市]
   ORDER BY 「年份」 ASC
11 LIMIT 0, 100
```



OAX访问协议



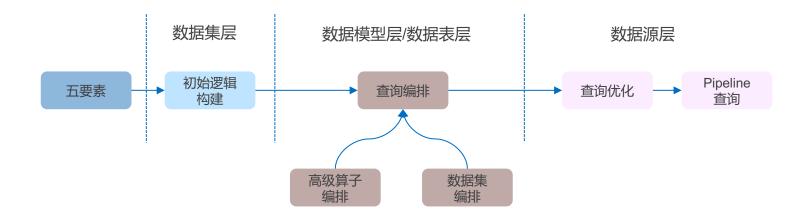




03 OAX Runtime设计

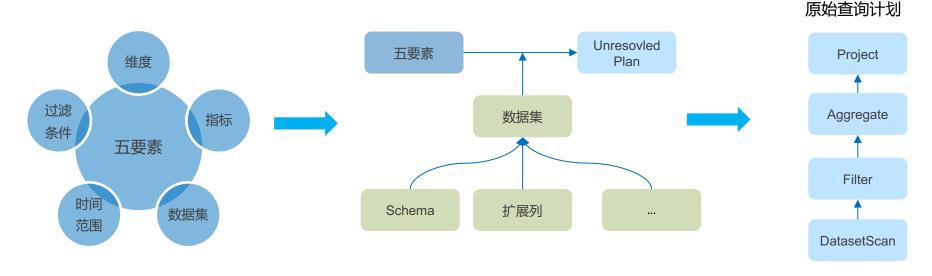


Runtime概览





初始逻辑构建



分析需求: 2020~2021年湖北省各市的GDP及占比

```
LogicalSort(sort0=[$0], dir0=[ASC], offset=[0], fetch=[100])

LogicalProject(年份=[$0], 省份=[$1], 城市=[$2], gdp=[$3], gdp_rate=[/($3, {EXCLUDE $2 : $3})])

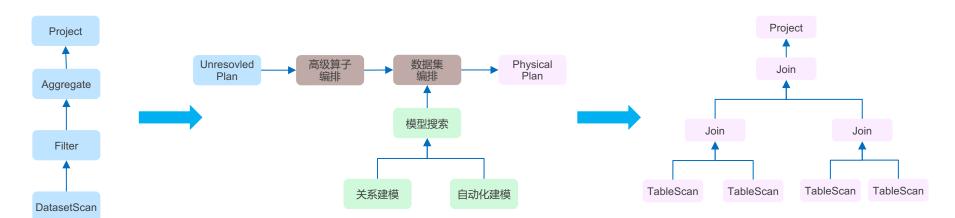
LogicalAggregate(group=[{0, 1, 2}], gdp=[SUM($3)])

LogicalFilter(condition=[AND(>=($0, '2020'), <=($0, '2021'), =($1, '湖北'))])

LogicalDatasetScan(table=[[国民经济数据集]]) --自定义LogicalDatasetScan节点
```



查询编排

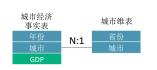


高级算子编排示例:



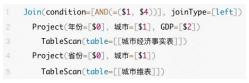
数据集编排示例:

LogicalTableScan(table=[[国民经济数据集]])



模型关系

数据集编排





查询优化

常规优化

- RBO优化
- CBO优化

计算路由

决策哪些节点在本地计算,哪些下推到引擎执行:

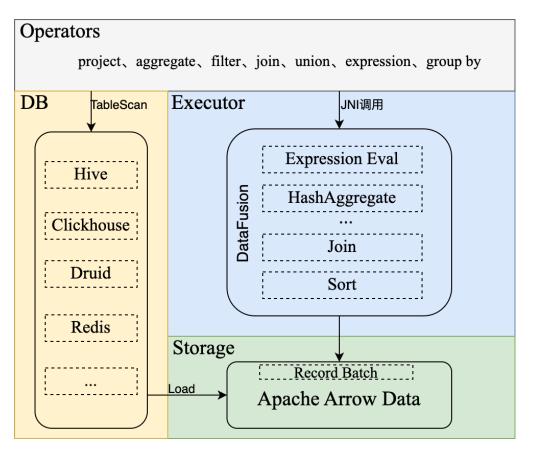
- 查询尽可能下推到物理引擎;
- 基于数据量级和查询代价进 行二次判定是否都下推到物 理引擎;

执行计划变换

通过自定义节点,实现某些引擎特有的查询能力, 比如Clickhouse的 LocalQuery等;



Pipeline查询

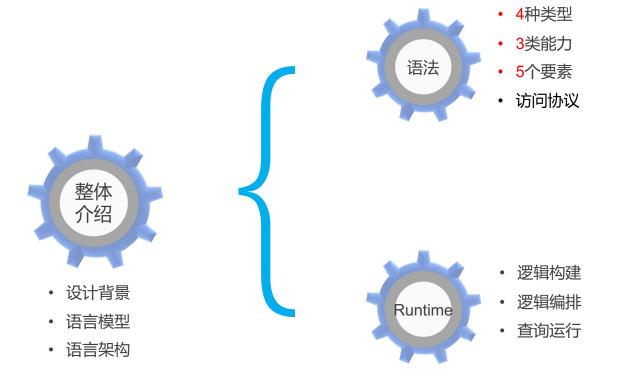




总结



OAX设计回顾





OAX的收益





欢迎技术交流



快手大数据公众号



非常感谢您的观看

器快手 | ★DataFun.

